۱- دهمین لایه

(آ) غلط است - چون پیوستگی لزوماً به معنای Compact بودن نیست، یک تابع Compact هم Closed است و هم Bounded که لزوماً با پیوستگی اتفاق نمی‌افتد. و بنابراین اینجا قرار ارسیست. universal Approximation Theorem

ب) درست - غیرخطی بودن باعث ایجاد non-convexity در تابع Loss خواهد و نهایتاً Loss Surface می‌شود.

پ) درست - Logistic Regression دقیقاً همین است.

ت) نادرست $y_i = \gamma \hat{x}_i + \beta$ - این ۲ پارامتر هایپر نیستند و Learnable هستند و بنابراین در حین آموزش update می‌شوند. نهایتاً هم برای بازیابی توزیع اصلی داده‌ها استفاده می‌شوند.

(بخش دوم)

آ- چون اینجا باعث ایجاد similarity در شبکه عصبی می‌شویم و عملاً تمام نورون‌های خروجی هر لایه، یکسان output خود را تولید می‌کنند. حتی در back prop هم گرادیان‌ها یکسان می‌شوند و هدف ما در شبکه عصبی که یادگیری پترن‌های پیچیده بود ارضا نمی‌شود زیرا همه نورون‌ها در حال یادگیری به یک شکل یکسان هستند.

ب- اگر همه لایه‌ها خطی باشند، عملاً یک لایه یا دو لایه یا n لایه تفاوتی نمی‌کند چون خروجی مدل $W_n W_{n-1} \dots W_1 x$ می‌گیرد و آن هم عملاً خطی می‌شود، از طرفی شبکه عصبی برای یادگیری تابع‌های Complex و non-linear استفاده می‌شود و اینجا حتی با تعداد لایه‌های زیاد نه تنها در حال یادگیری یک پترن خطی هستیم، بلکه اصلاً تفاوتی نمی‌کند یک لایه باشد یا n لایه عملاً با تلفیق ضرایب با همدیگر نیز هم می‌توان آن خروجی را گرفت.

Scanned with CamScanner

ب) Momentum باعث می‌شود علاوه بر گرادیان فعلی، از حافظه هم
جمله‌ای داشته باشیم که به جای حرکت نوسان‌دار و زیگزاگ مانند SGD ناشی از فقط
گرادیان فعلی می‌شود، در جهت‌های پایدار سرعت بگیریم. در واقع Momentum فرصت
به ما اجازه می‌دهد Convergence سریع‌تری داشته باشیم بدون اینکه در مواقعی باعث می‌شود
از local minima یا saddle point ها هم عبور کنیم و آنجا گیر نیوفتیم مانند SGD.

ت) با توزیع برنولی به هر نورون این احتمال را نسبت می‌دهد که خاموش یا روشن باشد.
و بنابراین تعمیم نورون‌ها در هر لایه به صورت رندوم خاموش می‌شوند. پس اگر یکی از نورون‌
ها وزن زیادی داشت و تاثیر زیادی بر شبکه و لایه بعد خود می‌گذاشت ممکن بود دچار overfit
شویم اما با dropout باعث می‌شویم که به نورون‌ها یا نورون‌های خاصی برای تصمیم‌گیری راجع
به داده‌های Train اتکا نکنیم. و با ensemble گرفتن از شبکه‌های مختلف با dropout به یک
strong learner نهایی برسیم. این خود باعث تعمیم‌پذیری هم می‌شود. ما در هنگام test
می‌خواهیم خروجی قطعی داشته باشیم بنابراین هیچ نورونی را خاموش نمی‌کنیم اما به وزن‌ها ضریب
p می‌دهیم که اسکیل خروجی به هم نریزد. در test اگر تصادفی خاموش کنیم هر بار نتیجه فرق می‌کند
که مطلوب ما نیست

۲- (ا)

$$a^{(1)} = W^{(1)}x + b^{(1)} = \begin{bmatrix} 1 & -1 \\ 0.5 & 0.5 \end{bmatrix}\begin{bmatrix} 2 \\ -1 \end{bmatrix} + \begin{pmatrix} 0 \\ -0.5 \end{pmatrix} = \begin{pmatrix} 3 \\ 1 \end{pmatrix}$$

$$h = ReLU(a^{(1)}) = \begin{bmatrix} \max(0,3) \\ \max(0,1) \end{bmatrix} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}$$

$$z^{(2)} = a^{(2)} = W^{(2)}h + b^{(2)} = [1 \quad -1.5]\begin{bmatrix} 3 \\ 1 \end{bmatrix} + 0.2 = 3 - 1.5 + 0.2 = 1.7$$

$$\hat{y} = \sigma(a^{(2)}) = \frac{1}{1+e^{-1.7}} \approx 0.85$$

(ب)

Scanned with CamScanner

(ب)

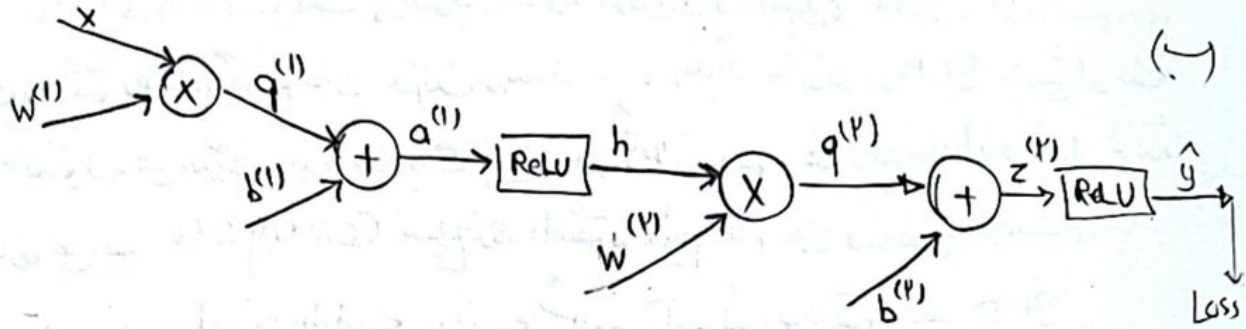

د

$y = 1 \quad \mathcal{L}(\hat{y}, 1) = -\ln(\hat{y})$

$\hat{y} = \dfrac{1}{1+e^{-z^{(2)}}}, \quad z^{(2)} = 1.7$

$$\left.\begin{aligned} \frac{\partial \mathcal{L}}{\partial \hat{y}} &= \frac{-1}{\hat{y}} \\ \frac{\partial \hat{y}}{\partial z^{(2)}} &= \hat{y}(1-\hat{y}) \end{aligned}\right\} \quad \frac{\partial \mathcal{L}}{\partial z^{(2)}} = \frac{-1}{\hat{y}}\,\hat{y}(1-\hat{y}) = \hat{y} - 1 = \frac{-1}{1+e^{1.7}}$$

$$\left.\begin{aligned} z^{(2)} &= W^{(2)}h + b^{(2)} \\ \frac{\partial z^{(2)}}{\partial W^{(2)}} &= h^T \end{aligned}\right\} \rightarrow \frac{\partial \mathcal{L}}{\partial W^{(2)}} = h^T \times \left(\frac{-1}{1+e^{1.7}}\right) = \begin{bmatrix} \frac{-3}{1+e^{1.7}} \\ \frac{-1}{1+e^{1.7}} \end{bmatrix}$$ پاسخ

$$\frac{\partial z^{(2)}}{\partial b^{(2)}} = 1 \longrightarrow \frac{\partial \mathcal{L}}{\partial b^{(2)}} = \frac{\partial \mathcal{L}}{\partial z^{(2)}} = \frac{-1}{1+e^{1.7}} \longrightarrow$$ پاسخ

$$\begin{cases} \dfrac{\partial z^{(2)}}{\partial h} = (W^{(2)})^T \\ \dfrac{\partial \mathcal{L}}{\partial h} = (W^{(2)})^T \dfrac{\partial \mathcal{L}}{\partial z^{(2)}} = (W^{(2)})^T \left(\dfrac{-1}{1+e^{1.7}}\right) = \begin{bmatrix} \frac{-1}{1+e^{1.7}} \\ \frac{1.5}{1+e^{1.7}} \end{bmatrix} \end{cases}$$

$\dfrac{\partial h}{\partial a^{(1)}} = 1 \longrightarrow$ both components of $a^{(1)}$ are positive

$$\frac{\partial \mathcal{L}}{\partial a^{(1)}} = \frac{\partial \mathcal{L}}{\partial h} = \begin{bmatrix} \frac{-1}{1+e^{1.7}} \\ \frac{1.5}{1+e^{1.7}} \end{bmatrix}$$

$$\frac{\partial a^{(1)}}{\partial b^{(1)}} = 1 \longrightarrow \frac{\partial \mathcal{L}}{\partial b^{(1)}} = 1 \times \frac{\partial \mathcal{L}}{\partial a^{(1)}} = \begin{bmatrix} \frac{-1}{1+e^{1.7}} \\ \frac{1.5}{1+e^{1.7}} \end{bmatrix}$$ پاسخ

$$\frac{\partial a^{(1)}}{\partial W^{(1)}} = x^T \longrightarrow \frac{\partial \mathcal{L}}{\partial W^{(1)}} = \begin{pmatrix} \frac{-1}{1+e^{1.7}} \\ \frac{3}{2(1+e^{1.7})} \end{pmatrix} \begin{pmatrix} 2 & -1 \end{pmatrix} = \begin{pmatrix} \frac{-2}{1+e^{1.7}} & \frac{1}{1+e^{1.7}} \\ \frac{3}{1+e^{1.7}} & \frac{-3}{1+e^{1.7}} \end{pmatrix}$$ پاسخ

Scanned with CamScanner

(ب) (۱) تعداد پارامترها $= (n+1)k + (k+1)m$

(۲) $m=1,\ n=2,\ k=2$

$3\times 2 + 3\times 1 = 9$

(ت) با اضافه کردن یک لایه جدید تعداد کل پارامترهای قابل آموزش افزایش می‌یابد. در نتیجه ترکیب‌های غیرخطی بیشتر می‌شوند و شبکه عصبی ما قادر به تقریب توابع Complex تر و غیرخطی تر است پس مدل آرازی مدل هم زیاد می‌شود، شبکه ما ممکن است نویز داده را هم یاد بگیرد و به همین علت منجر به بیش برازش شود.

سوال سوم

(آ)

$W^{[1]} \in \mathbb{R}^{D_a \times D_x}$ $\quad b^{(1)} \in \mathbb{R}^{D_a \times 1}$

$W^{[2]} \in \mathbb{R}^{K \times D_a}$ $\quad b^{[2]} \in \mathbb{R}^{K \times 1}$

if $X \in \mathbb{R}^{D_x \times m}$, $Z^{[1]} \in \mathbb{R}^{D_a \times m}$, $a^{[1]} \in \mathbb{R}^{D_a \times m}$

شکل خروجی بایاس‌ها ← $D_a \times m$ است.

(ب)

$$\frac{\partial \hat{y}_k}{\partial z_j^{[2]}} = ? \qquad \hat{y}_k = \frac{\exp(z_k^{[2]})}{\sum_{j=1}^{k} \exp(z_j^{[2]})}$$

$$j = k \Rightarrow \frac{\partial \hat{y}_k}{\partial z_k^{[2]}} = \hat{y}_k(1-\hat{y}_k)$$

(پ)

$$\text{if } i \neq k \Rightarrow \frac{\partial \hat{y}_k}{\partial z_i^{[2]}} = -\hat{y}_k \hat{y}_i$$

(ت)

$$\rightarrow L = -y_k \log(\hat{y}_k) = -\log(\hat{y}_k)$$

$$\frac{\partial L}{\partial z_i^{[2]}} = \frac{\partial \hat{y}_j^{(2)}}{\partial z_j^{(2)}} \frac{\partial L}{\partial \hat{y}_j^{(2)}}$$

if $i=k$: $\frac{-1}{\hat{y}_k}\hat{y}_k(1-\hat{y}_k) = \hat{y}_k - 1$

if $i \neq k$: $\frac{-1}{\hat{y}_k}(-\hat{y}_k \hat{y}_i) = \hat{y}_i$

$$\frac{\partial L}{\partial \hat{y}_i^{(2)}} = \frac{-1}{\hat{y}_i}$$

$$\frac{\partial \hat{y}_i}{\partial z_j^{(2)}} = \begin{cases} \hat{y}_i(1-\hat{y}_i) & i=j \\ -\hat{y}_i \hat{y}_j & i \neq j \end{cases}$$

$$\Rightarrow \frac{\partial L}{\partial z_i^{[2]}} = \hat{y}_i - y_i$$

Scanned with CamScanner

ث)

$$z^{[2]} = W^{[2]} a^{[1]} + b^{[2]}$$

$$\frac{\partial z^{[2]}}{\partial a^{[1]}} = (W^{[2]})^T = \delta_1$$

ج)

$$\delta_2 = \frac{\partial a_r^{[1]}}{\partial z_r^{[1]}} = \begin{cases} 1 & \text{if } z_r^{[1]} > 0 \\ \alpha & \text{if } z_r^{[1]} < 0 \end{cases}$$

$$a^{[1]} = \text{LeakyRELU}(z^{[1]}, \alpha), \quad \alpha = 0.01$$

چ)

$$\boxed{\frac{\partial L}{\partial z^{[2]}} = \delta_0 = \hat{y}_i - y_i}$$

$$\boxed{\frac{\partial L}{\partial W^{[2]}} = \frac{\partial z^{[2]}}{\partial a^{[1]}} \frac{\partial L}{\partial z^{[2]}} = (W^{[2]})^T \delta_0}$$

$$z^{[1]} = W^{[1]} x + b^{[1]}$$

$$\frac{\partial z^{[1]}}{\partial W^{[1]}} = x^T \qquad \frac{\partial L}{\partial W^{[1]}} = \frac{\partial L^T}{\partial z^{[2]}} \frac{\partial z^{[2]}}{\partial a^{[1]}} \frac{\partial a^{[1]}}{\partial z^{[1]}} \frac{\partial z^{[1]}}{\partial W^{[1]}}$$

⇐ درواری برعکس می‌شود

$$\frac{\partial z^{[1]}}{\partial b^{[1]}} = I$$

$$\boxed{\begin{aligned} \frac{\partial L}{\partial W^{[1]}} &= x^T \delta_2 \delta_1 \delta_0 \\ \frac{\partial L}{\partial b^{[2]}} &= \delta_2 \delta_1 \delta_0 \end{aligned}}$$

ح) اگر بعضی از $z_i^{[2]}$ منفی بود $\exp(z_i^{[2]})$ ممکن است به بی‌نهایت میل کند و نسبت ما بی‌معنی بشود، و اگر $z_i^{[2]}$ منفی هم کوچک و نزدیک به ۰ باشد، $\exp(z_i^{[2]})$ به صفر کرد می‌شود و دقت از بین می‌رود. در این فرمول ما کنیم $z_i^{[2]}$ را کم می‌کنیم و چون داریم $z_i^{[2]} - m \leq 0$ همه توان‌ها یا منفی می‌شوند پس حاصل exp آن همواره کوچکتر مساوی 1 خواهد بود. از طرفی چون مخرج e^{-m} با این تغییر در همه جا اضافه می‌شود صورت و مخرج مخرج e^{-m} ساده می‌شوند و هیچ تفاوتی با تابع سافت‌مکس قبلی ندارد.

خ) چون تنسورفلو کند چون همان طور که اشاره شد این تابع همان تابع قبلی است و فقط شکل و شمایل آن عوض شده. از طرفی m هم ثابت است نسبت به انیس i در نتیجه در نسبت نهایی حذف شده بنابراین ژاکوبین همان قبلی باقی می‌ماند.

Scanned with CamScanner

سوال ششم:

$$\alpha_t = \alpha_0 e^{-kt} \quad , \quad \alpha_0 = 0.1 \quad , \quad k = 0.05$$

آ)

$$g(t) = \nabla_\theta \hat{J}_t(\theta_t) \qquad \theta_{t+1} \leftarrow \theta_t - \alpha_t g(t)$$

$$\theta_{t+1} \leftarrow \theta_t - 0.1 e^{-0.05t}$$

ب) نرخ یادگیری ما یک تابع متغیر نمایی با ضریب منفی انتخاب شده که به این معناست که هرچه جلوتر می‌رویم، نرخ یادگیری یا α_t بیشتر و بیشتر به صفر نزدیک می‌شود. در ابتدا اما نرخ یادگیری ما زیاد است و ما در ابتدا می‌فهمیم سریعاً جابجا شویم و از تلاش بد از minima ها عبور کنیم. ولی هرچه به ناحیه مورد نظر یک minima نزدیک‌تر می‌شویم باید گام های کوچکتری برداریم تا منجر به exploding gradient نشود. بنابراین با نوسان کم در زمان های بیشتر راحت‌تر converge می‌کنیم به local minima اما دیرتر یعنی هم به همگرایی و هم به پایداری فرآیند آموزش بهبود می‌بخشد.

پ) با نرخ یادگیری ثابت، اگر شیب تند باشد یعنی گرادیان ما بزرگ است پس نوسان خود و ناپایدار به نقطه بهینه ما نزدیک می‌شود و حتی ممکن است منجر به همگرایی هم نشود. اگر گرادیان ما ما کاهشی باشد یا گذشت زمان اگر این شیب تند کم می‌شود و در نتیجه با نوسان های کوچکتر و کوچکتری به نقطه بهینه نزدیک می‌شویم.

ت)

$$\sum_{t=1}^{\infty} \alpha_t = \infty \qquad \sum_{t=1}^{\infty} \alpha_t^2 < \infty$$

$$\sum_{t=1}^{\infty} \alpha_0 e^{-kt} = \alpha_0 \frac{e^{-k}}{1-e^{-k}} < \infty \longrightarrow$$ شرط اول صدق نمی‌کند ⚠

استفاده از فرمول سری هندسی — مقدار متناهی

$$k > 0 \quad 0 < e^{-k} < 1 \longrightarrow 1 - e^{-k} > 0$$

$$\sum_{t=1}^{\infty} \alpha_t^2 = \sum_{t=1}^{\infty} \alpha^2 e^{-2kt} = \alpha^2 \frac{e^{-2k}}{1-e^{-2k}} < \infty \longrightarrow$$ شرط دوم صدق می‌کند

این تابع α_t در شرایط رایج همگرا به طور کامل صدق نمی‌کند. اگر بخواهیم تعدیل کنیم باید بگوییم به دلیل ضریب -0.05 در توان نمایی، این گرادیان کاهشی خیلی زود کاهش را اعمال می‌کند و بنابراین ممکن است قبل از رسیدن به یک نقطه بهینه تقریباً دچار vanishing gradient شویم.

Scanned with CamScanner

سوال هفتم:

الف)

$$g_i = \frac{\partial L}{\partial y_i}$$

$$y_i = \gamma \hat{x}_i + \beta$$

$$\frac{\partial L}{\partial \beta} = \sum_{i=1}^{m} \frac{\partial L}{\partial y_i} \frac{\partial y_i}{\partial \beta} = \sum_{i=1}^{m} g_i$$

$$\frac{\partial L}{\partial \gamma} = \sum_{i=1}^{m} \frac{\partial L}{\partial y_i} \frac{\partial y_i}{\partial \gamma} = \sum_{i=1}^{m} g_i \hat{x}_i$$

ب)

$$\frac{\partial L}{\partial \hat{x}_i} = \frac{\partial L}{\partial y_i} \frac{\partial y_i}{\partial \hat{x}_i} = g_i \gamma$$

$$\tilde{g}_i = \frac{\partial L}{\partial \hat{x}_i} = g_i \gamma \qquad s = \sqrt{\sigma_B^2 + \epsilon} \qquad \hat{x}_i = \frac{x_i - \mu_B}{s}$$

$$\frac{\partial L}{\partial x_i} = \frac{1}{s}\left(\tilde{g}_i - \frac{1}{m}\sum_{j=1}^{m} \tilde{g}_j - \frac{\hat{x}_i}{m}\sum_{j=1}^{m} \tilde{g}_j x_j\right)$$

$$\frac{\partial L}{\partial x_i} = \frac{\gamma}{\sqrt{\sigma_B^2 + \epsilon}}\left(g_i - \frac{1}{m}\sum_{j=1}^{m} g_j - \frac{\hat{x}_i}{m}\sum_{j=1}^{m} g_j \hat{x}_j\right)$$

ج)

$$\sum_{i=1}^{m} \frac{\partial L}{\partial x_i} = \frac{\gamma}{\sqrt{\sigma_B^2 + \epsilon}}\left(\underbrace{\sum_{i=1}^{m} g_i}_{0} - \underbrace{\sum_{i=1}^{m} \frac{1}{m} \sum_{j=1}^{m} g_j}_{\sum_{j=1}^{m} g_j} - \underbrace{\sum_{i=1}^{m} \frac{\hat{x}_i}{m} \sum_{j=1}^{m} g_j \hat{x}_j}_{0}\right)$$

$$\rightarrow \sum_{i=1}^{m} \hat{x}_i = \sum_{i=1}^{m} \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} = \frac{1}{\sqrt{\sigma_B^2 + \epsilon}}\left(\sum_{i=1}^{m} x_i - m\mu_B\right) = 0$$

$$\rightarrow \sum_{i=1}^{m} \frac{\partial L}{\partial x_i} = 0$$

یعنی اگر $x_i \leftarrow x_i + c$ چون BN میانگین را از آنها کم می‌کند، $\hat{x}_i$ ها تغییر نمی‌کنند و در نهایت نسبت به این شیفت حساسیت ندارد.

Scanned with CamScanner